

# Netiesinių lygčių sistemų sprendimas

# Temoje aiškinama:

- **NLS matematinė formuluotė ir grafinis sprendimo būdas;**
- Paprastųjų iteracijų algoritmas NLS sprendimui;
- **Niutono metodas NLS sprendimui. Niutono-Rafsono metodas;**
- Kvazi-Niutono metodai. Broideno metodas;

**NLS matematinė formuluotė ir grafinis  
sprendimo būdas**

# Netiesinių algebrinių lygčių sprendimas. Matematinė formuluotė

$$f(x) = 0$$

Vieno kintamojo lygtis  
(skaliarinė skaliarinio  
argumento funkcija)

$$\mathbf{f}(\mathbf{x}) =$$

$$\begin{Bmatrix} f_1(x_1, x_2, \dots, x_n) \\ f_2(x_1, x_2, \dots, x_n) \\ \vdots \\ f_n(x_1, x_2, \dots, x_n) \end{Bmatrix} = \begin{Bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{Bmatrix}$$

„**Bold**“ šriftas reiškia  
vektorių arba matricą

Lygčių sistema su  
daugeliu kintamųjų  
(vektorinė vektorinio  
argumento funkcija)

$$\mathbf{f}(\mathbf{x}) = \begin{Bmatrix} f_1(x_1, x_2, \dots, x_n) \\ f_2(x_1, x_2, \dots, x_n) \\ \vdots \\ f_n(x_1, x_2, \dots, x_n) \end{Bmatrix} = \begin{Bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{Bmatrix}$$



pavyzdys

$$\mathbf{f}(\mathbf{x}) = \begin{Bmatrix} x_1^2 + x_2^2 - 2 \\ x_1^2 - x_2^2 \end{Bmatrix} = \begin{Bmatrix} 0 \\ 0 \end{Bmatrix}$$

# Netiesinių algebrinių lygčių sistemų sprendimas. Pradinio artinio nustatymas

- Daugiamatėje kintamųjų ir funkcijų erdvėje universalių metodų pradiniam artiniui rasti nėra;
- Atskiroms lygčių klasėms dažnai pavyksta parinkti neblogą pradinį priartėjimą remiantis išankstinėmis žiniomis apie nagrinėjamą objektą;
- Dviejų kintamųjų atveju lygčių sistemai ištirti galima panaudoti funkcijų grafinį vaizdavimą

# Grafinis metodas 2 lygčių sistemai MATLAB

```
x=[-5:0.5:5];  
y=[-6:0.5:6];
```

```
for i=1:length(x), for j=1:length(y)  
    Z(i,j,1:2)=f ([x(i),y(j)]);  
end, end
```

← Lygčių sistemos  
funkcijų reikšmės

```
figure(1), hold on  
mesh(x,y,Z(:,:,1));  
contour(x,y,Z(:,:,1)',[0 0]);
```

← 1 funkcijos paviršius

← 1 funkcijos nulinio reikšmių linija

```
figure(2), hold on  
mesh(x,y,Z(:,:,2));  
contour(x,y,Z(:,:,2)',[0 0]);
```

← 2 funkcijos paviršius

← 2 funkcijos nulinio reikšmių linija

```
figure(3), hold on  
contour(x,y,Z(:,:,1)',[0 0]);  
contour(x,y,Z(:,:,2)',[0 0]);  
end
```

← Abiejų nulinio reikšmių linijų  
susikirtimai yra sprendinio  
taškai

```
function fff=f(x) % Lygčių sistemos funkcija  
    fff=[x(1)^2+x(2)^2-2;  
        x(1)^2-x(2)^2];  
  
return  
end
```

# Grafinis metodas 2 lygčių sistemai Python

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits import mplot3d
import math

def LF(x): #----- Lygciu sistemos funkcija-----
    s=np.matrix( [[x[0]**2+x[1]**2-2], [x[0]**2-x[1]**2]])
    return s
#-----

fig1=plt.figure(1,figsize=plt.figaspect(0.5));
ax1 = fig1.add_subplot(1, 2, 1, projection='3d'); ax2 = fig1.add_subplot(1, 2, 2, projection='3d');
plt.draw();

xx=np.linspace(-5,5,20);yy=np.linspace(-6,6,20);
X, Y = np.meshgrid(xx, yy);
Z=np.zeros(shape=(len(xx),len(yy),2))
for i in range (0,len(xx)):
    for j in range (0,len(yy)): Z[i,j,:]=LF([X[i][j],Y[i][j]]).transpose();

surf1 = ax1.plot_surface(X, Y, Z[:, :,0], color='blue', alpha=0.4)
CS11 = ax1.contour(X, Y, Z[:, :,0],[0],colors='b')

surf2 = ax1.plot_surface(X, Y, Z[:, :,1], color='purple', alpha=0.4)
CS12 = ax1.contour(X, Y, Z[:, :,1],[0],colors='g')

CS1 = ax2.contour(X, Y, Z[:, :,0],[0],colors='b')
CS2 = ax2.contour(X, Y, Z[:, :,1],[0],colors='g')


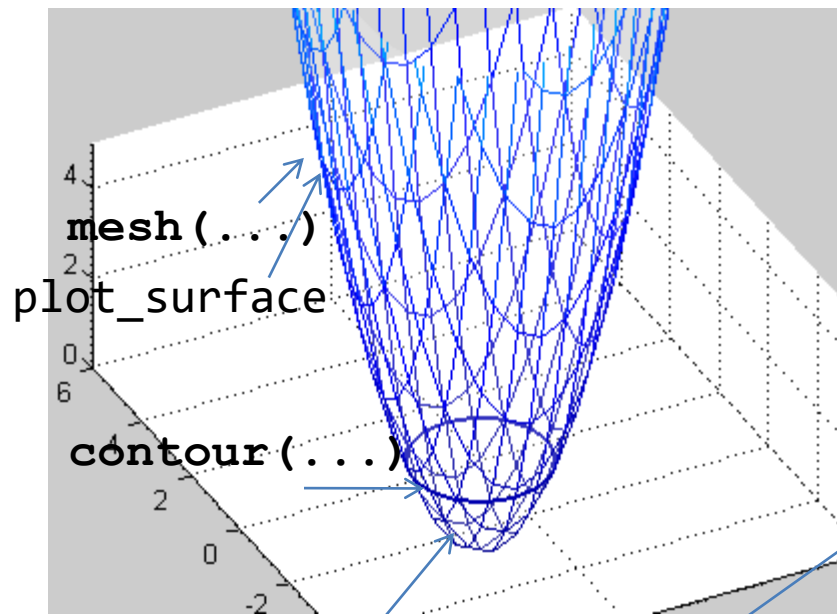
plt.show()
```

1 funkcijos paviršius ir nulinio reikšmių linija


2 funkcijos paviršius ir nulinio reikšmių linija

Abiejų nulinio reikšmių linijų susikirtimai yra sprendinio taškai





$$\begin{cases} f_1(x_1, x_2) = x_1^2 + x_2^2 - 2 = 0; \\ f_2(x_1, x_2) = x_1^2 - x_2^2 = 0 \end{cases}$$



# Paprastųjų iteracijų algoritmas NLS sprendimui

# Netiesinių algebrinių lygčių sprendimas. Paprastųjų iteracijų metodas (1)

$$\mathbf{f}(\mathbf{x}) = 0 \quad \longrightarrow \quad \mathbf{x} = \mathbf{x} + [\mathbf{a}]^{-1} \mathbf{f}(\mathbf{x})$$

$$[\mathbf{a}]\mathbf{x} = \mathbf{f}(\mathbf{x}) + [\mathbf{a}]\mathbf{x}$$

$\mathbf{x}^0$  - pradinis artinys

Gali būti įstrižaininė  
matrica

$$\mathbf{x}^{i+1} = \mathbf{x}^{(i)} + [\mathbf{a}]^{-1} \mathbf{f}(\mathbf{x}^{(i)}) , \quad i = 0, 1, 2, 3, \dots$$


# Netiesinių algebrinių lygčių sprendimas.

## Paprastųjų iteracijų metodas (2)

$$\mathbf{x}^{i+1} = \mathbf{x}^{(i)} + [\alpha]^{-1} \mathbf{f}(\mathbf{x}^{(i)}), \quad i = 0, 1, 2, 3, \dots$$

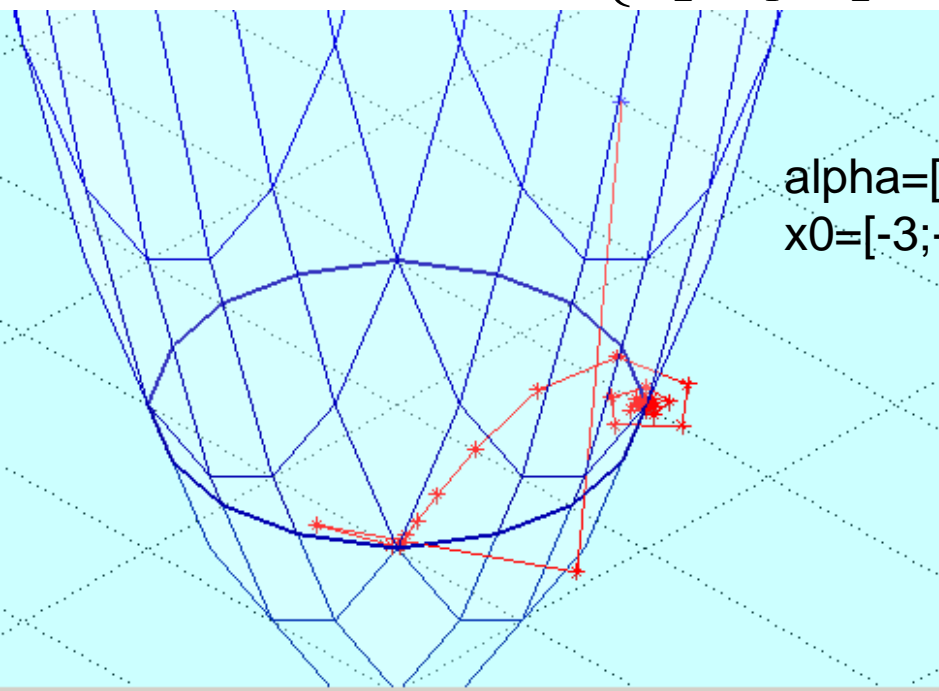

$$[\alpha] = \begin{bmatrix} \alpha_1 & 0 & 0 & \dots & 0 \\ 0 & \alpha_2 & 0 & \dots & 0 \\ 0 & 0 & \alpha_3 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \alpha_n \end{bmatrix} \quad \Rightarrow \quad [\alpha]^{-1} = \begin{bmatrix} 1/\alpha_1 & 0 & 0 & \dots & 0 \\ 0 & 1/\alpha_2 & 0 & \dots & 0 \\ 0 & 0 & 1/\alpha_3 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1/\alpha_n \end{bmatrix}$$

- Įstrižaininės matricos inversija gaunama, invertuojant įstrižainės elementus;
- Matricos **alpha** inversija ir daugyba iš matricos paprastųjų iteracijų formulės dešinėje pusėje reiškia, kad kiekvienas funkcijos vektoriaus elementas dalijamas iš atitinkamos **alpha** reikšmės




alpha=[1;1]\*3;  
x0=[-3;-1.2];

$$\begin{cases} f_1(x_1, x_2) = x_1^2 + x_2^2 - 2 = 0; \\ f_2(x_1, x_2) = x_1^2 - x_2^2 = 0 \end{cases}$$



alpha=[1;1]\*2.45;  
x0=[-3;-1.2];



**Niutono metodos NLS sprendimui.  
Niutono-Rafsono metodos**

# Netiesinių algebrinių lygčių sprendimas.

Atkirstoji Teiloro eilutė vektorinio argumento vektorinės funkcijos atveju

$$\mathbf{f}(\mathbf{x}) = 0, \quad \mathbf{x}^{(0)} - \text{pradinis artinys}$$

$$f_k(\mathbf{x} + \Delta\mathbf{x}) \approx f_k(\mathbf{x}) + \Delta x_1 \left. \frac{\partial f_k}{\partial x_1} \right|_{\mathbf{x}} + \Delta x_2 \left. \frac{\partial f_k}{\partial x_2} \right|_{\mathbf{x}} + \dots + \Delta x_n \left. \frac{\partial f_k}{\partial x_n} \right|_{\mathbf{x}}, \quad k = 1:n$$

Atkirsta Teiloro eilutė

$$\begin{Bmatrix} f_1(\mathbf{x} + \Delta\mathbf{x}) \\ f_2(\mathbf{x} + \Delta\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x} + \Delta\mathbf{x}) \end{Bmatrix} = \begin{Bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_n(\mathbf{x}) \end{Bmatrix} + \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}_{\mathbf{x}} \begin{Bmatrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{Bmatrix}$$

Jakobio matricos  
eilutėse įrašyti  
vektorinės funkcijos  
komponenčių  
gradientų vektoriai

# Netiesinių algebrinių lygčių sprendimas.

## Niutono metodas

Sprendžiame prieaugiais:

$$\mathbf{x}^{i+1} = \mathbf{x}^i + \Delta \mathbf{x}$$



$$\begin{Bmatrix} f_1(\mathbf{x}^{i+1}) \\ f_2(\mathbf{x}^{i+1}) \\ \vdots \\ f_n(\mathbf{x}^{i+1}) \end{Bmatrix} \approx \begin{Bmatrix} f_1(\mathbf{x}^i) \\ f_2(\mathbf{x}^i) \\ \vdots \\ f_n(\mathbf{x}^i) \end{Bmatrix} + \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}_{\mathbf{x}^i} \begin{Bmatrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{Bmatrix}$$

Po argumentų prieaugio funkcijos reikšmė, apskaičiuota pagal pirmus Teiloro eilutės narius turi tapti lygia 0:

$$\mathbf{f}(\mathbf{x}^{i+1}) = 0 \quad \Rightarrow \quad \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{\mathbf{x}^i} \Delta \mathbf{x} = -\mathbf{f}(\mathbf{x}^i); \quad \Rightarrow \quad \Delta \mathbf{x} = - \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{\mathbf{x}^i}^{-1} \mathbf{f}(\mathbf{x}^i)$$

$$\mathbf{x}^{i+1} = \mathbf{x}^i - \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{\mathbf{x}^i}^{-1} \mathbf{f}(\mathbf{x}^i)$$

- Užrašas simboliais toks pats, kaip ir Niutono metodo formulė vienai netiesinei lygčiai;
- Skiriasi tai, kad čia  $\mathbf{x}$  ir  $\mathbf{f}$  yra vektoriai, o vietoje funkcijos išvestinės įrašoma vektorinės funkcijos Jakobio matrica



# Netiesinių algebrinių lygčių sprendimas.

## Niutono metodas

Niutono metodo iteracijų formulė:



$$\mathbf{x}^{i+1} = \mathbf{x}^i - \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{\mathbf{x}^i} \right]^{-1} \mathbf{f}(\mathbf{x}^i)$$

Vykdamas algoritmą, **neverta apskaičiuoti atvirkštinę matricą**. Geriau kiekvienoje iteracijoje *spręsti tiesinių lygčių sistemą*:

$$\left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{\mathbf{x}^i} \right] \Delta \mathbf{x} = -\mathbf{f}(\mathbf{x}^i) \quad \Rightarrow \quad \Delta \mathbf{x} \quad \Rightarrow \quad \mathbf{x}^{i+1} = \mathbf{x}^i + \Delta \mathbf{x}$$

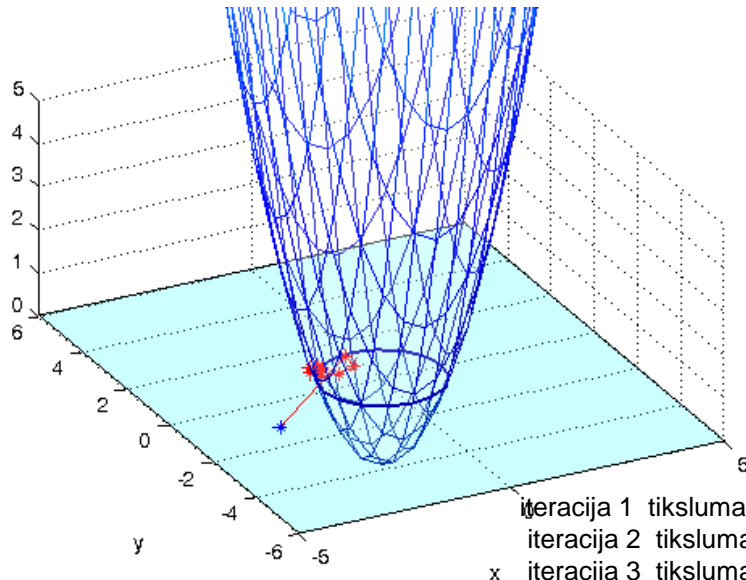
Jeigu Niutono metodas diverguoja, galima bandyti *sumažinti prieaugio dydį*:

$$\mathbf{x}^{i+1} = \mathbf{x}^i + \beta \Delta \mathbf{x} \quad , \quad 0 < \beta \leq 1$$




iteracija 1 tikslumas 0.294054  
 iteracija 2 tikslumas 0.214649  
 iteracija 3 tikslumas 0.0766578  
 iteracija 4 tikslumas 0.00547262  
 sprendinys  $x = -1.00784 \ -1$



# Palyginkime: ta pati lygčių sistema sprendžiama paprastųjų iteracijų metodu ( $\alpha=[1;1]*3$ )



iteracija 1 tikslumas 11.3308  
iteracija 2 tikslumas 1.72202  
iteracija 3 tikslumas 1.45521  
iteracija 4 tikslumas 1.15575  
iteracija 5 tikslumas 0.879586  
iteracija 6 tikslumas 0.751667  
iteracija 7 tikslumas 0.533435  
iteracija 8 tikslumas 0.399402  
iteracija 9 tikslumas 0.286547  
iteracija 10 tikslumas 0.214062  
iteracija 11 tikslumas 0.161948  
iteracija 12 tikslumas 0.121426  
iteracija 13 tikslumas 0.0908646  
iteracija 14 tikslumas 0.0669444  
iteracija 15 tikslumas 0.0499964  
iteracija 16 tikslumas 0.0371301  
iteracija 17 tikslumas 0.027856  
iteracija 18 tikslumas 0.0207214  
iteracija 19 tikslumas 0.0154719  
iteracija 20 tikslumas 0.0114985  
iteracija 21 tikslumas 0.0085788  
sprendinys  $\mathbf{x} = -0.997614 \ 0.998122$




- PI metodu radome kitą sprendinį, negu Niutono metodu;
- Šis sprendinys nėra artimiausias pradiniam artiniui



- Sprendžiant Niutono metodu, kiekvienos lygties funkcijai artinio taške brėžiama liestinė (hiper)plokštuma;
- Liestinės plokštumos kertasi su nuline plokštuma (hiper)tiesėmis;
- Sekantis artinys parenkamas gautųjų (hiper)tiesių susikirtimo taške

# Niutono metodo grafinė interpretacija 2 lygčių sistemos atveju

*Pvz\_SMA\_5\_09\_Niutono\_metodas\_2\_LS\_gradientai.m*



**% Lygciu sistemos funkcija**

**function** fff=f(x)

fff=0.05\*[x(1)^2+x(2)^2-2;  
-(x(1)-3)^2-x(2)^2+3];

**return**

**end**


**% Jakobio matrica**

**function** dff=df(x)

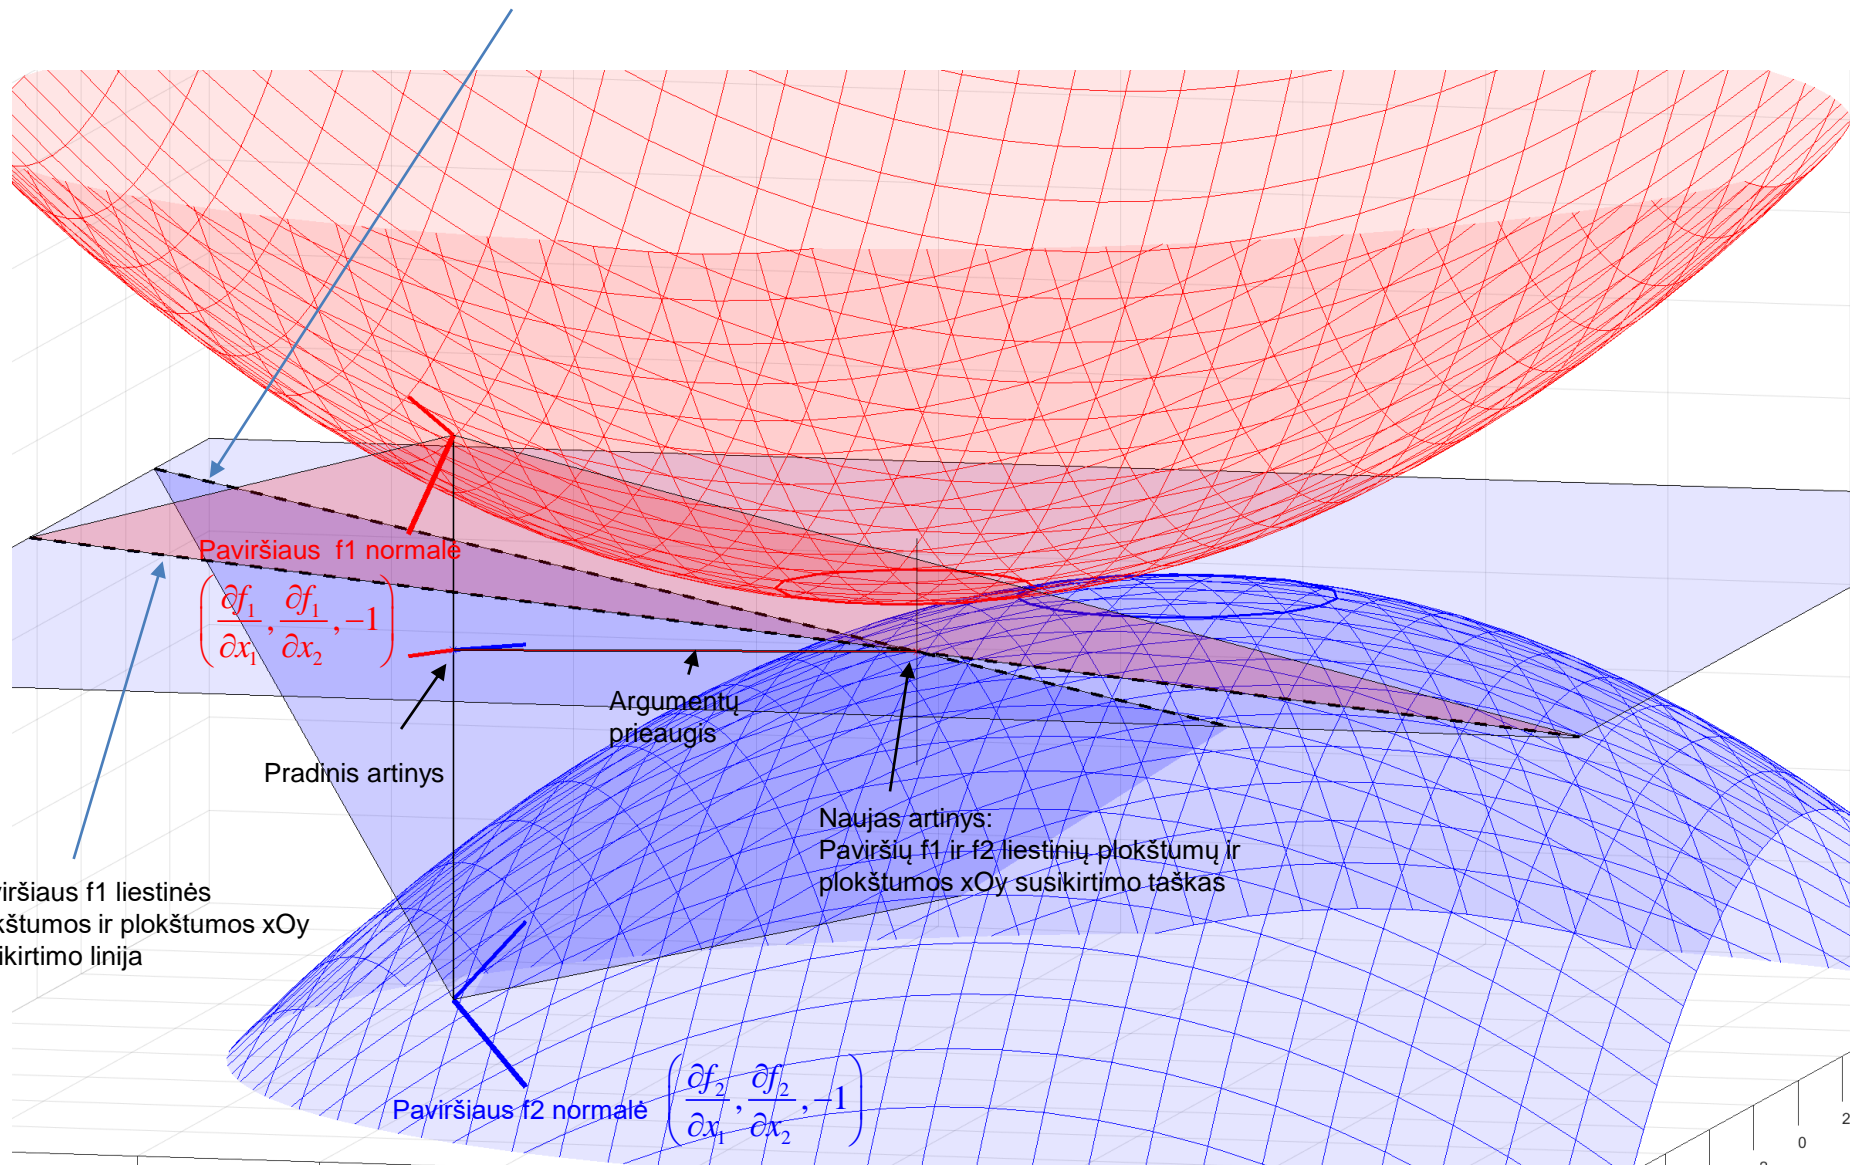
dff=0.05\*[2\*x(1), 2\*x(2);  
-2\*(x(1)-3), -2\*x(2)];

**return**

**end**



Paviršiaus f2 liestinės plokštumos ir  
plokštumos xOy susikirtimo linija



# **Netiesinių algebrinių lygčių sprendimas.**

## **Niutono metodas – apibendrinimai (1)**

- **Niutono metodas visuomet konverguoja, kai pradedama skaičiuoti nuo gero pradinio artinio;**
- **Kiekvienos iteracijos metu reikia apskaičiuoti funkcijos ir Jakobio matricos reikšmes**

**Jakobio matricos reikšmę galima įvertinti skaitiškai, nenaudojant analitinių diferencijavimo formulių:**

$$\mathbf{x}^{i+1} = \mathbf{x}^i - \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{\mathbf{x}^i} \right]^{-1} \mathbf{f}(\mathbf{x}^i)$$



$$\frac{\partial f_i}{\partial x_j} = \frac{f_i(x_1, x_2, \dots, x_j + h, \dots, x_n) - f_i(x_1, x_2, \dots, x_j, \dots, x_n)}{h}$$

Lygčių sistemos atveju, Jakobio matricos radimui kiekvienos iteracijos metu tektų  $2n^2$  kartų apskaičiuoti funkcijų reikšmes. Tai neekonomiška skaičiavimų imlumo požiūriu.



# Jakobio matricos skaitinio įverčio apskaičiavimas Python:

```
import numpy as np

def numerical_jacobi(f,x,dx):
    # f - vektorine funkcija, aprasyta kaip def
    # x - vektorinis argumentas
    # dx - argumentu pokytis, skaitiskai ivertinant isvestines, skaliarinis dydis
    n=np.size(f(x));m=np.size(x);
    J=np.matrix(np.zeros((n,m),dtype=float))
    x1=np.matrix(x)
    for j in range (m): x1[j]=x[j]+dx; J[:,j]=(f(x1)-f(x))/dx; x1[j]=x[j];
    return J

def f1(x):
    fff=np.vstack((np.power(x[0],2)+np.power(x[1],2)-2,np.power(x[0],2)-np.power(x[1],2)))
    return fff

x=np.matrix([[1],[1]],dtype=float)
print(numerical_jacobi(f1,x,0.000001))
```



$$\mathbf{f}(\mathbf{x}) = \begin{Bmatrix} x_1^2 + x_2^2 - 2 \\ x_1^2 - x_2^2 \end{Bmatrix}$$

$$\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} 2x_1 & 2x_2 \\ 2x_1 & -2x_2 \end{bmatrix} \approx \begin{bmatrix} 2.0000001 & 2.0000001 \\ 2.0000001 & -2.0000001 \end{bmatrix}$$

# Netiesinių algebrinių lygčių sprendimas.

## Niutono metodas – apibendrinimai (2)

### Rafsono modifikacija:

- Jakobio matricos reikšmės galima atnaujinti ne kiekvienoje iteracijoje, tačiau *kas tam tikrą skaičių iteracijų*;
- Konvergavimo sparta sumažėja, tačiau kiekvienoje iteracijoje sumažėja atliekamų veiksmų skaičius. Suminis sprendimo laikas dažniausiai gaunamas mažesnis;
- Toks sprendimo būdas vadinamas *Niutono-Rafsono metodu*

# **Kvazi-Niutono metodai. Broideno metodas**

# Kvazi-Niutono metodai: Broideno metodas (1)

Niutono metodo iteracijų formulė:

$$\mathbf{x}^{i+1} = \mathbf{x}^i - \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{\mathbf{x}^i} \right]^{-1} \mathbf{f}(\mathbf{x}^i)$$

**kvazi-Niutono** =  
„lyg ir Niutono“,  
„tartum Niutono“


- Siekiame apytiksliai apskaičiuoti Jakobio matricą;  $\longrightarrow \left[ \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \bigg|_{\mathbf{x}^i} \right] \approx \mathbf{A}_i$
- Apytikslė Jakobio matrica apskaičiuojama panašiai, kaip ir **kirstinių metode**, t.y. pagal **dabartinį ir prieš tai apskaičiuotąjį artinius**:

$$\mathbf{A}_i (\mathbf{x}^i - \mathbf{x}^{i-1}) = \mathbf{f}(\mathbf{x}^i) - \mathbf{f}(\mathbf{x}^{i-1})$$

$$\mathbf{A}_i \mathbf{s} = \mathbf{y}$$

- Iš tokios lygčių sistemos matricos **A** elementų vienareikšmiškai apskaičiuoti nepavyktų;
- Sistema turi  $n$  lygčių ir  $n^2$  nežinomųjų;
- **Nežinomieji yra visi matricos **A** elementai, o vektoriai **s** ir **y** yra žinomi**

# Broideno metodo idėja: vektoriaus projekcija į plokštumą 3D erdvėje



$$\vec{z}' = \vec{z} - \vec{\omega}(\vec{\omega} \cdot \vec{z}) = \begin{Bmatrix} z_x \\ z_y \\ z_z \end{Bmatrix} - \begin{Bmatrix} \omega_x \\ \omega_y \\ \omega_z \end{Bmatrix} \left( \begin{Bmatrix} \omega_x & \omega_y & \omega_z \end{Bmatrix} \begin{Bmatrix} z_x \\ z_y \\ z_z \end{Bmatrix} \right) =$$

$$= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{Bmatrix} z_x \\ z_y \\ z_z \end{Bmatrix} - \begin{Bmatrix} \omega_x \\ \omega_y \\ \omega_z \end{Bmatrix} \left( \begin{Bmatrix} \omega_x & \omega_y & \omega_z \end{Bmatrix} \begin{Bmatrix} z_x \\ z_y \\ z_z \end{Bmatrix} \right) = \mathbf{E} \mathbf{z} - \mathbf{\omega} \mathbf{\omega}^T \mathbf{z} = \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\|\mathbf{s}\|^2} \right) \mathbf{z} = \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) \mathbf{z}$$

Projekcijos matrica



## Brodeno metodas (2)

$$\mathbf{Z}^* = \left( \mathbf{E} - \frac{\mathbf{s}\mathbf{s}^T}{\mathbf{s}^T\mathbf{s}} \right) \mathbf{Z}$$



- Matricos  $\mathbf{Z}^*$  **stulpeliai** yra matricos  $\mathbf{Z}$  **stulpelių** (t.y. vektorių) projekcijų į duotą plokštumą vektoriai;
- Projekcijos plokštuma yra statmena vektoriui  $\mathbf{s}$

$$(\mathbf{Z}^*)^T = \mathbf{Z}^T \left( \mathbf{E} - \frac{\mathbf{s}\mathbf{s}^T}{\mathbf{s}^T\mathbf{s}} \right)$$



- Matricos  $(\mathbf{Z}^*)^T$  **eilutės** yra matricos  $(\mathbf{Z})^T$  **eilučių** (t.y. vektorių) projekcijų į duotą plokštumą vektoriai;
- Projekcijos plokštuma yra statmena vektoriui  $\mathbf{s}$  ;
- Projekcijos matrica  $\left( \mathbf{E} - \frac{\mathbf{s}\mathbf{s}^T}{\mathbf{s}^T\mathbf{s}} \right)$  yra simetrinė, todėl ji išlieka tokia pati abiem atvejais

# Broideno metodas (3)

- Apytikslei Jakobio matricai apskaičiuoti priimame papildomą sąlygą, kad atnaujinta matrica sekančioje iteracijoje būtų kiek galima artimesnė prieš tai naudotai matricai;
- Pareikalaujame, kad nepakistų atnaujintos matricos  $A$  eilučių, kaip vektorių, projekcijos į hiperplokštumą, statmeną prieš tai atliktoje iteracijoje apskaičiuoto kintamųjų prieaugio vektoriui;
- Siekiame išlaikyti nepakitusius ne stulpelių, o būtent eilučių projekcijų vektorius, kadangi kiekvienoje Jakobio matricos eilutėje yra įrašytas kiekvienos funkcijų vektoriaus komponentės **gradiento vektorius**

$$\begin{cases} \mathbf{A}_i \mathbf{s} = \mathbf{y}; \\ \mathbf{A}_i \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) = \mathbf{A}_{i-1} \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) \end{cases}$$

$$\begin{aligned} \mathbf{s} &= \mathbf{x}^i - \mathbf{x}^{i-1} \\ \mathbf{y} &= \mathbf{f}(\mathbf{x}^i) - \mathbf{f}(\mathbf{x}^{i-1}) \end{aligned}$$

# Brodeno metodos (4)

$$\begin{cases} \mathbf{A}_i \mathbf{s} = \mathbf{y}; \\ \mathbf{A}_i \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) = \mathbf{A}_{i-1} \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right); \end{cases}$$

$$\bullet \frac{\mathbf{s}^T}{\mathbf{s}^T \mathbf{s}}$$

Iš šio vektoriaus padauginame abi pirmos lygties puses

$$\begin{cases} \mathbf{A}_i \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} = \frac{\mathbf{y} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \\ \mathbf{A}_i \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) = \mathbf{A}_{i-1} \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right); \end{cases}$$

$$\mathbf{A}_i = \mathbf{A}_{i-1} + \frac{(\mathbf{y} - \mathbf{A}_{i-1} \mathbf{s}) \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}}$$

$$\mathbf{s} = \mathbf{x}^i - \mathbf{x}^{i-1}$$

$$\mathbf{y} = \mathbf{f}(\mathbf{x}^i) - \mathbf{f}(\mathbf{x}^{i-1})$$



# Broideno metodas (5)

$$\mathbf{x}^0, \mathbf{A}_0$$



Pradinis sprendinio artinys ir skaitiniu diferencijavimu gautas arba laisvai parinktas Jakobio matricos artinys

$$\mathbf{A}_{i-1} \mathbf{s}_i = -\mathbf{f}(\mathbf{x}^{i-1});$$



Argumentų prieaugiu apskaičiavimas

$$\mathbf{x}^i = \mathbf{x}^{i-1} + \mathbf{s}_i$$



Sekantis artinys

$$\mathbf{y}_i = \mathbf{f}(\mathbf{x}^i) - \mathbf{f}(\mathbf{x}^{i-1});$$



Funkcijos reikšmės pokytis


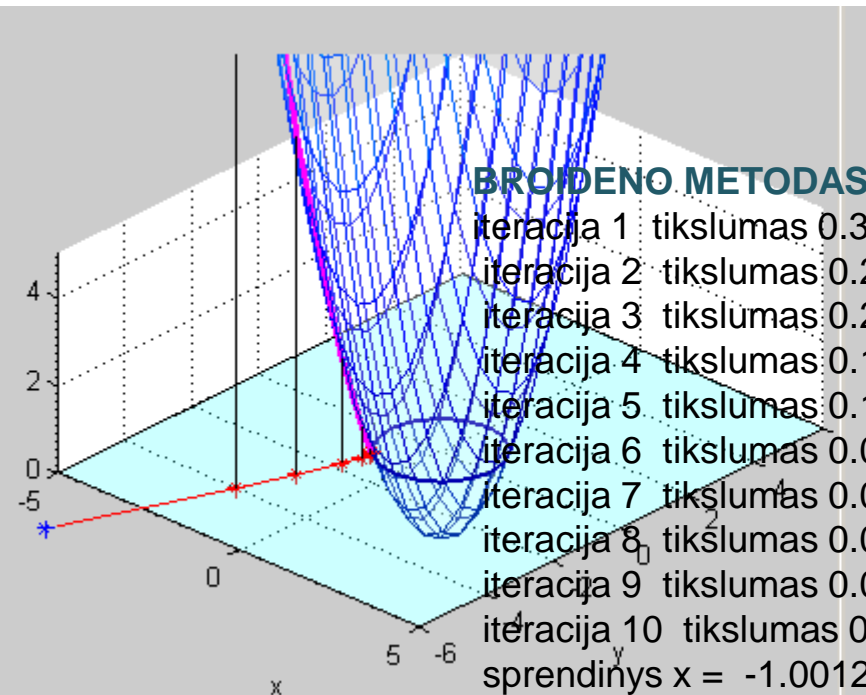


$$\mathbf{A}_i = \mathbf{A}_{i-1} + \frac{(\mathbf{y}_i - \mathbf{A}_{i-1} \mathbf{s}_i) \mathbf{s}_i^T}{\mathbf{s}_i^T \mathbf{s}_i};$$




Jakobio matricos atnaujinimas pagal Broideno formulę

$$i = 1, 2, \dots$$

- Apskaičiavę naują artinį, pagal jo reikšmę atnaujiname ir Jakobio matricą;
- Atliekant pirmąją iteraciją,  $\mathbf{A}_0$  jau turi būti tam tikru būdu apskaičiuotas;
- $\mathbf{A}_0$  galima apskaičiuoti, taikant skaitinio diferencijavimo veiksmą, arba parinkti tam tikrą įstrižaininę matricą





$$\mathbf{x}^0, \mathbf{A}_0$$

$$\mathbf{A}_{i-1} \mathbf{s}_i = -\mathbf{f}(\mathbf{x}^{i-1});$$

$$\mathbf{x}^i = \mathbf{x}^{i-1} + \mathbf{s}_i$$

$$\mathbf{y}_i = \mathbf{f}(\mathbf{x}^i) - \mathbf{f}(\mathbf{x}^{i-1});$$

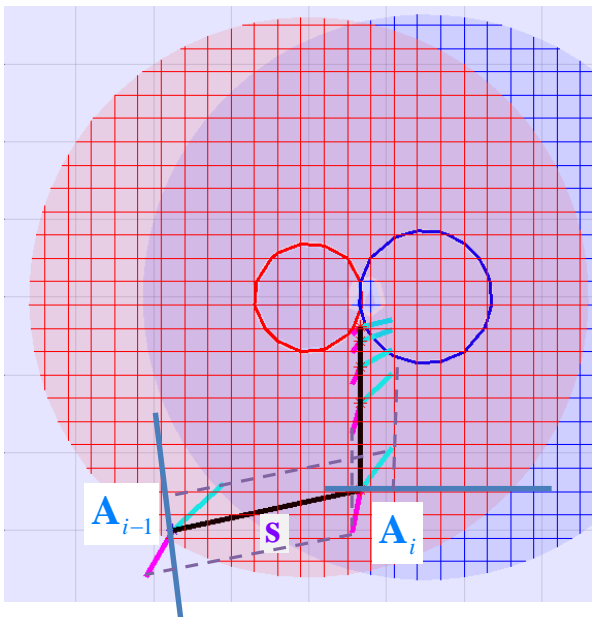
$$\mathbf{A}_i = \mathbf{A}_{i-1} + \frac{(\mathbf{y}_i - \mathbf{A}_{i-1} \mathbf{s}_i) \mathbf{s}_i^T}{\mathbf{s}_i^T \mathbf{s}_i};$$

$$i = 1, 2, \dots$$

# Broideno metodo grafinė interpretacija 2 lygčių sistemos atveju


[Pvz\\_SMA\\_5\\_08\\_Broideno\\_metodas\\_2\\_LS\\_gradientai.m](#)

[Pvz\\_SMA\\_5\\_09\\_Niutono\\_metodas\\_2\\_LS\\_gradientai.m](#)



$$\begin{cases} \mathbf{A}_i \mathbf{s} = \mathbf{y}; \\ \mathbf{A}_i \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) = \mathbf{A}_{i-1} \left( \mathbf{E} - \frac{\mathbf{s} \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}} \right) \end{cases} \Rightarrow \mathbf{A}_i = \mathbf{A}_{i-1} + \frac{(\mathbf{y} - \mathbf{A}_{i-1} \mathbf{s}) \mathbf{s}^T}{\mathbf{s}^T \mathbf{s}}$$
$$\mathbf{s} = \mathbf{x}^i - \mathbf{x}^{i-1}; \quad \mathbf{y} = \mathbf{f}(\mathbf{x}^i) - \mathbf{f}(\mathbf{x}^{i-1})$$

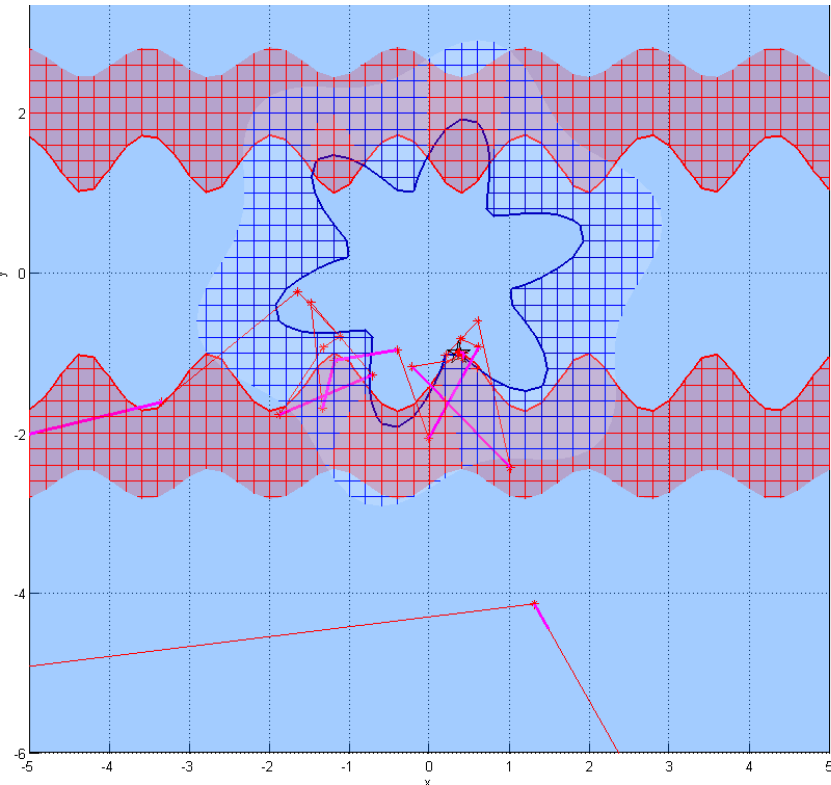
- Tik pradiniai gradientai yra tikslūs, kiek tą galima pasiekti skaitiniu diferencijavimu;
- Sprendžiant Broideno metodu, apytikslėje Jakobio matricoje gradientų projekcijos į paskutiniam argumentų prieaugiui statmeną plokštumą yra vienodos. Tačiau patys gradientai yra apytiksliai



- Palyginkime: Niutono metodu gaunami gradientai

```
function fff=f(x)    % Lygciu sistemos funkcija
    fff=[sin(4*x(1))+x(2)^2-2;
        x(1)^2+x(2)^2-(0.5*sin(6*atan(x(2)/x(1))))+1.5)^2];

    return
end
```



### NIUTONO METODAS

iteracija 1 tikslumas 0.33704  
 iteracija 2 tikslumas 0.766926

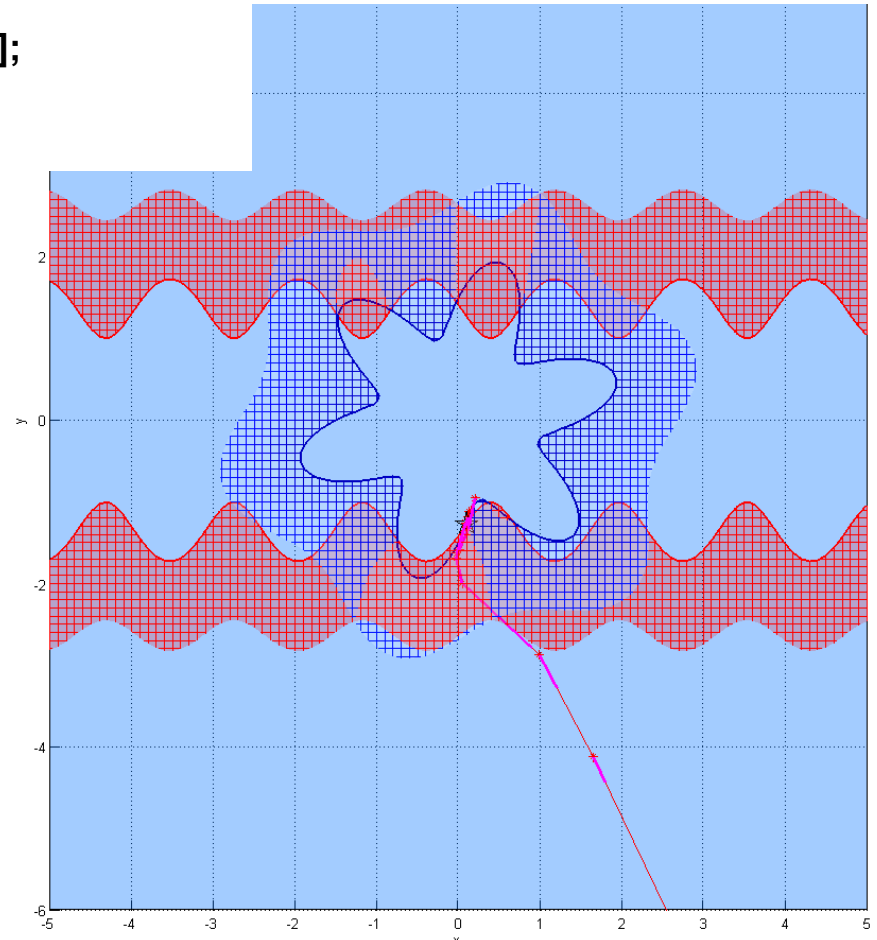
.

.

.

iteracija 29 tikslumas 1.87904e-05  
 iteracija 30 tikslumas 3.61564e-06  
 sprendinys x = 0.365414 -1.00297

*Pvz\_SMA\_5\_3x, 5\_6x*



### BROIDENO METODAS

iteracija 1 tikslumas 0.329564  
 iteracija 2 tikslumas 0.241526

.

.

.

iteracija 18 tikslumas 6.96362e-05  
 iteracija 19 tikslumas 1.58517e-06  
 sprendinys x = 0.0997217 -1.26949

## SMA\_05\_Klausimai savikontrolei(1):

1. Kaip parenkamas netiesinių lygčių sistemos (NLS) sprendinio pradinis artinys;
2. Kaip parenkamas netiesinių lygčių sistemos (NLS) sprendinio pradinis artinys;  
Paaiškinkite, kaip būtų galima grafiškai rasti dviejų NLS sprendinį;
3. Užrašykite Paprastųjų iteracijų metodo formulę bendrojo pavidalo NLS sprendimui. Kuo ji panaši ir kuo skiriasi nuo vienos netiesinės lygties sprendimo iteracinės formulės;
4. Kokį vaidmenį atlieka koeficientai "alpha" Paprastųjų iteracijų metode;
5. Kuo skiriasi Teiloro eilutės formulė vienmatėje ir daugiamatėje kintamųjų erdvėje;

## SMA\_05\_Klausimai savikontrolei(2):

6. Kokia yra Teiloro eilutės pirmųjų dviejų narių formulė, užrašyta matricomis. Kas yra Jakobio matrica;
7. Kaip gaunama Niutono metodo formulė daugiamatėje kintamųjų erdvėje;
8. Paaiškinkite du Niutono metodo formulės pavidalus, kai naudojama atvirkštinė matrica ir kai kiekviename žingsnyje sprendžiama lygčių sistema. Kuris pavidalas pranašesnis. Ar skiriasi sprendinio artinių seka, gauta taikant kiekvieną iš šių pavidalų;
9. Kokie yra svarbiausi Niutono metodo privalumai ir trūkumai;
10. Kas yra Niutono metodo Rafsono modifikacija (t.y. Niutono-Rafsono metodas). Ko ja siekiama;
11. Ar galima taikyti Niutono metodą, jeigu nėra galimybės analitiškai apskaičiuoti funkcijų išvestinių (Jakobio matricos). Ką reiškia terminas "kvazi-Niutono metodas";

## SMA\_05\_Klausimai savikontrolei(3):

12. Paaiškinkite, kodėl daugiamatėje kintamųjų erdvėje nepavyksta tiesiogiai taikyti dviejų nuosekliai gautų sprendinio artinių Jakobio matricos įverčiui apskaičiuoti;
13. Koks metodas yra Broideno metodo analogas, sprendžiant vieną netiesinę lygtį;
14. Paaiškinkite Broideno metodo idėją;
15. Naudodamiesi skaidrėmis, paaiškinkite veiksmų seką, atliekamą vykdant vieną Broideno metodo iteraciją;