

Funkcijų aproksimavimas:

Aproksimavimas daugianariais

Funkcijų aproksimavimas. **Uždavinio** **formuluotė**

Aproksimavimas – tai funkcijos, kurios reikšmės aproksimavimo taškuose būtų ***kiek galima mažiau nutolusios*** nuo duotųjų reikšmių, radimas.

1. Kreivė $y=f(x)$ neprivalo praeiti per duotus taškus (x_i, y_i) , t. y. $f(x_i)=y_i$, $i=1, 2, \dots, n$;
2. funkcijos $f(x)$ analitinė išraiška neturi būti labai sudėtinga;
3. funkcija $f(x)$ turi būti nesunkiai integruojama ir diferencijuojama;
4. funkcija $f(x)$ turi būti nesunkiai surandama (pvz., jos parametrai apskaičiuojami pagal žinomas formules, arba sprendžiant tiesinių lygčių sistemą).

Funkcijų aproksimavimas *mažiausių kvadratų* metodu

Taškų seka, kurią reikia aproksimuoti: (x_i, y_i) , $i = 1, \dots, n$

$$\Psi = \frac{1}{2} \sum_{j=1}^n \left(f(x_j) - y_j \right)^2$$

Aproksimacijos
kokybės įverčio
funkcija

$$\min_f \Psi$$

ieškoma funkcija

Funkcijų *interpoliavimas* yra atskiras
funkcijų *aproksimavimo* uždavinio atvejis

Aproksimavimas daugianariais *vienanarių bazėje*

Taškų seka, kurią reikia aproksimuoti: (x_i, y_i) , $i = 1, \dots, n$

Duotų taškų skaičius ir aproksimuojančių funkcijų skaičius gali nesutapti: $m \leq n$

Aproksimuojančios funkcijos
ieškosime parinktų *bazinių*
funkcijų tiesinės
kombinacijos pavidale

$$f(x) = [g_1(x) \quad g_2(x) \quad \dots \quad g_{m-1}(x) \quad g_m(x)] \begin{Bmatrix} c_1 \\ c_2 \\ \vdots \\ c_{m-1} \\ c_m \end{Bmatrix} = [\mathbf{g}(x)] \{\mathbf{c}\}$$

↑
Bazinės funkcijos

↑
koeficientai

Aproksimavimo kokybės įverčio funkcija užrašoma matricomis

$$f(x_j) - y_j$$



$$\begin{Bmatrix} f(x_1) - y_1 \\ f(x_2) - y_2 \\ \vdots \\ f(x_n) - y_n \end{Bmatrix} = \begin{bmatrix} g_1(x_1) & g_2(x_1) & \cdots & g_m(x_1) \\ g_1(x_2) & g_2(x_2) & \cdots & g_m(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ g_1(x_n) & g_2(x_n) & \cdots & g_m(x_n) \end{bmatrix} \begin{Bmatrix} c_1 \\ c_2 \\ \vdots \\ c_m \end{Bmatrix} - \begin{Bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{Bmatrix} = [\mathbf{G}]_{n \times m} \{\mathbf{c}\}_{m \times 1} - \{\mathbf{y}\}_{n \times 1}$$



$$\min_{\mathbf{c}} \Psi = \frac{1}{2} (\mathbf{Gc} - \mathbf{y})^T (\mathbf{Gc} - \mathbf{y})$$



$$\left(\frac{\partial \Psi}{\partial \mathbf{c}} \right)^T = 0$$

ieškomi koeficientai

Pagal priimtus žymėjimus, skaliarinės funkcijos išvestinė pagal vektorinį argumentą (gradientas) yra matrica-eilutė. Standartinio pavidalo lygčių sistemą gausime, jį pateikę stulpeliu, t.y. transponuodami

Pagalbinė medžiaga: matricų ir vektorių išraiškų diferencijavimo formulės

$$f = \mathbf{x}^T \mathbf{x} = \sum_{i=1}^n x_i^2;$$

$$\left[\frac{\partial f}{\partial \mathbf{x}} \right] = \left\{ \frac{\partial f}{\partial x_1} \quad \frac{\partial f}{\partial x_2} \quad \cdots \quad \frac{\partial f}{\partial x_n} \right\} = 2 \{ x_1 \quad x_2 \quad \cdots \quad x_n \} = 2\mathbf{x}^T; \quad \longleftarrow \text{gradientas}$$

$$f = \mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j;$$

$$\left[\frac{\partial f}{\partial \mathbf{x}} \right] = \left\{ \frac{\partial f}{\partial x_1} \quad \frac{\partial f}{\partial x_2} \quad \cdots \quad \frac{\partial f}{\partial x_n} \right\} = \left[\sum_{j=1}^n (a_{1j} + a_{j1}) x_j \quad \sum_{j=1}^n (a_{2j} + a_{j2}) x_j \quad \cdots \quad \sum_{j=1}^n (a_{nj} + a_{jn}) x_j \right] = \mathbf{x}^T (\mathbf{A} + \mathbf{A}^T)$$

gradientas



$$\mathbf{f} = \mathbf{A} \mathbf{x}$$

$$\left[\frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right] = \left[\frac{\partial (\mathbf{A} \mathbf{x})}{\partial \mathbf{x}} \right] = \mathbf{A} \left[\frac{\partial \mathbf{x}}{\partial \mathbf{x}} \right] = \mathbf{A} \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = \mathbf{A}; \quad \longleftarrow \text{Jakobio matrica}$$

Aproksimavimo kokybės įverčio minimumo sąlyga

$$\Psi = \frac{1}{2} (\mathbf{G}\mathbf{c} - \mathbf{y})^T (\mathbf{G}\mathbf{c} - \mathbf{y})$$



$$\frac{\partial \Psi}{\partial \mathbf{c}} = \frac{\partial \Psi}{\partial (\mathbf{G}\mathbf{c} - \mathbf{y})} \frac{\partial (\mathbf{G}\mathbf{c} - \mathbf{y})}{\partial \mathbf{c}} = (\mathbf{G}\mathbf{c} - \mathbf{y})^T \mathbf{G}$$




$$\left(\frac{\partial \Psi}{\partial \mathbf{c}} \right)^T = \mathbf{G}^T (\mathbf{G}\mathbf{c} - \mathbf{y}) = 0$$

$$\frac{\partial (\mathbf{x}^T \mathbf{x})}{\partial \mathbf{x}} = 2\mathbf{x}^T$$



$$\frac{\partial (\mathbf{A}\mathbf{x})}{\partial \mathbf{x}} = \mathbf{A}$$



Pagal priimtus žymėjimus,
skaliarinės funkcijos išvestinė
pagal vektorinį argumentą yra
matrica-eilutė

Gautą priklausomybę laikysime
lygčių sistema, todėl standartinis jos
pavidalas gaunamas transponuojant

$$\left(\left(\mathbf{G}^T \right)_{m \times n} \mathbf{G}_{n \times m} \right)_{m \times m} \mathbf{c}_{m \times 1} = \left(\mathbf{G}^T \right)_{m \times n} \mathbf{y}_{n \times 1}$$



Lygčių skaičius toks, kiek yra bazinių funkcijų, t.y. m .
Jis nepriklauso nuo duotų aproksimavimo taškų skaičiaus

Koeficientų apskaičiavimas aproksimavimo ir interpoliavimo atveju

aproksimavimas

$$\left(\left(\mathbf{G}^T \right)_{m \times n} \mathbf{G}_{n \times m} \right)_{m \times m} \mathbf{c}_{m \times 1} = \left(\mathbf{G}^T \right)_{m \times n} \mathbf{y}_{n \times 1}$$

Kairiojo matricinio daugiklio
negalima išbraukti, kadangi
pasikeistų lygčių skaičius



$m = n$

$$\cancel{\left(\mathbf{G}^T \right)_{n \times n}} \mathbf{G}_{n \times n} \mathbf{c}_{n \times 1} = \cancel{\left(\mathbf{G}^T \right)_{n \times n}} \mathbf{y}_{n \times 1}$$

Kairįjį daugiklį atmetus, lygčių
skaičius nepakinta, o sistema
išlieka išsprendžiama



$$\mathbf{G}_{n \times n} \mathbf{c}_{n \times 1} = \mathbf{y}_{n \times 1}$$

interpoliavimas

Aproksimavimo vienanariais eiga

```
function G=base(m,x)
    for i=1:m, G(:,i)=x.^(i-1); end
return,end
```

$G = \text{base}(m, X(1:n))$

Duoti aproksimavimo
taškai X

$$\mathbf{G} = \begin{bmatrix} g_1(x_1) & g_2(x_1) & \cdots & g_m(x_1) \\ g_1(x_2) & g_2(x_2) & \cdots & g_m(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ g_1(x_n) & g_2(x_n) & \cdots & g_m(x_n) \end{bmatrix} = \begin{bmatrix} 1 & x_1 & \cdots & x_1^{m-1} \\ 1 & x_2 & \cdots & x_2^{m-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^{m-1} \end{bmatrix}$$

$$(\mathbf{G}^T \mathbf{G}) \mathbf{c} = \mathbf{G}^T \mathbf{y}$$

Aproksimuojančios
funkcijos vaizdavimas:

$$f(x) = [\mathbf{g}(x)] \{\mathbf{c}\}$$

Vaizdavimo taškai (linspace)

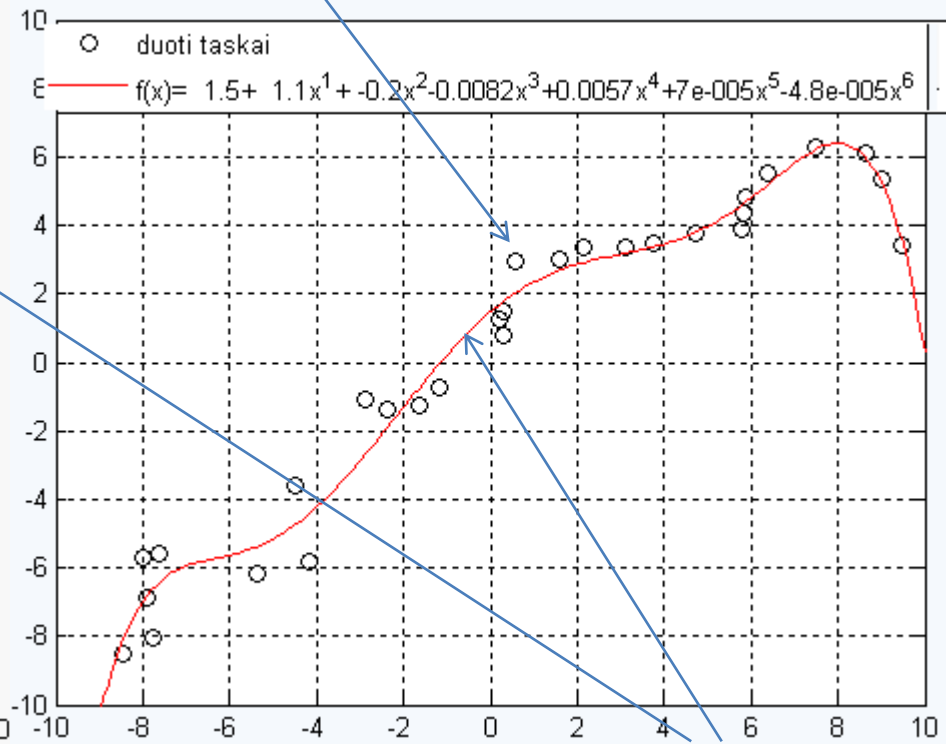
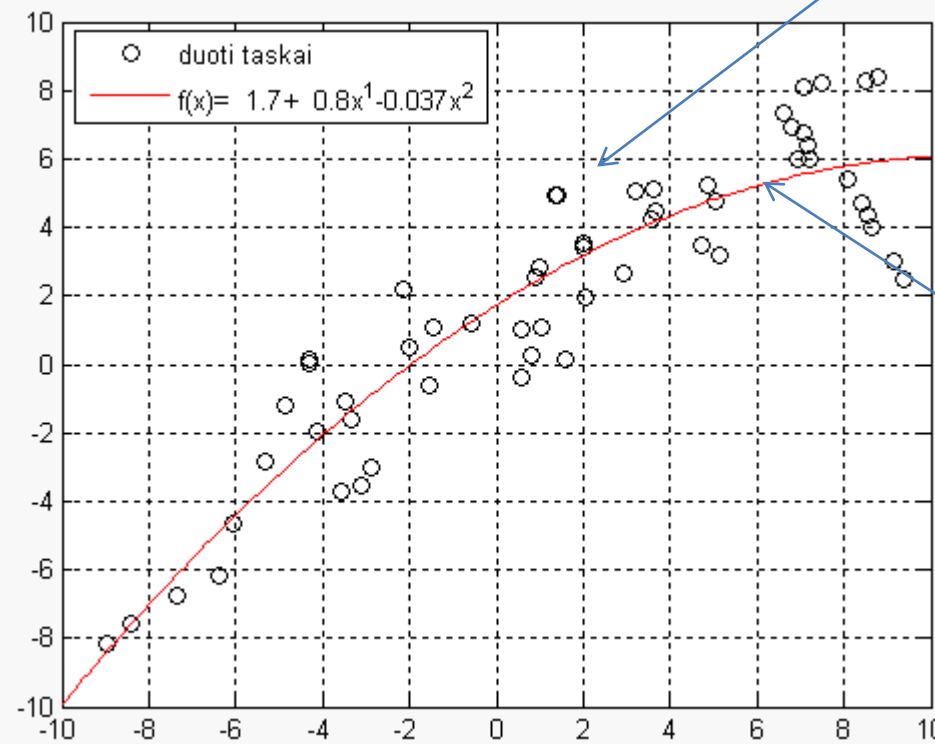
Aproksimavimas daugianariais *vienanarių bazėje*

Pvz_SMA_9_1_aproksimavimas_vienanariu_baze

Taškų seka, kurią reikia aproksimuoti: (x_i, y_i) , $i = 1, \dots, n$

Bazinės funkcijos:

$$\begin{bmatrix} 1 & x & x^2 & \dots & x^{m-1} \end{bmatrix}$$



$$\mathbf{G}^T \mathbf{G} \mathbf{c} = \mathbf{G}^T \mathbf{y}$$


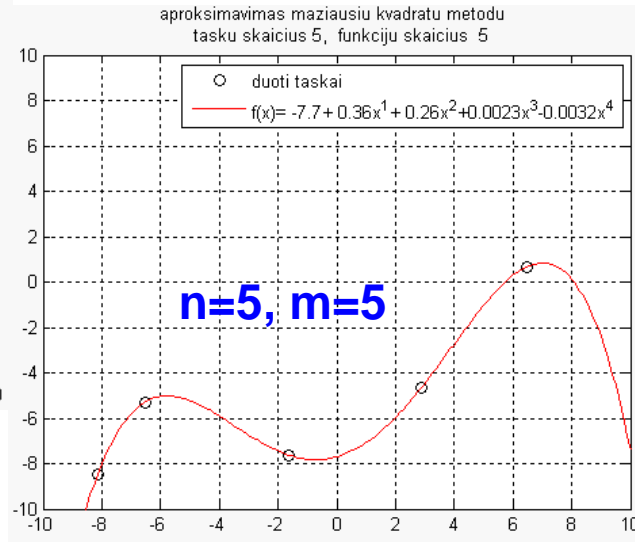



\mathbf{c}



$\tilde{\mathbf{G}} \mathbf{c}$

Kai **bazinių funkcijų skaičius** ir **aproksimuojamų taškų skaičius** sutampa ($n=m$), aproksimuojanči kreivė praeina per visus taškus: $\min_f \Psi = 0$



Interpoliavimo uždavinys yra aproksimavimo uždavinio atskiras atvejis, kai $n=m$

- Mažiausių kvadratų būdu sukurta aproksimuojanti kreivė dar vadinama **regresijos kreive**

*Regresijos terminas yra naudojamas kaip antonimas žodžiui **progresuoti** (tobulėti, išsiskirti iš vidurkio). Regresuoti – prarasti gerąsias savybes, artėti prie vidurkio. Regresijos kreivė aprašo taškų vidurines padėtis;*

- Aproksimavimui apibūdinti dar naudojamas terminas **kreivės pritaikymas (curve fitting)**

Vektorinio argumento funkcijų aproksimavimas

Taškų aibė, kurią reikia aproksimuoti: (x_i, y_i, z_i) , $i = 1, \dots, n$

$$\Psi = \frac{1}{2} \sum_{j=1}^n \left(f(x_j, y_j) - z_j \right)^2$$

Aproksimacijos kokybės įverčio funkcija → Ψ

$\min \Psi$

f ← **ieškoma funkcija**

argumento vektorius → (x_j, y_j)

$$f(x, y) = \begin{bmatrix} g_1(x, y) & g_2(x, y) & \dots \end{bmatrix} \begin{Bmatrix} c_1 \\ c_2 \\ \vdots \end{Bmatrix} = \begin{bmatrix} \mathbf{g}(x, y) \end{bmatrix} \{\mathbf{c}\}$$

Bazinių funkcijų vektorius → $\begin{bmatrix} g_1(x, y) & g_2(x, y) & \dots \end{bmatrix}$

koeficientai → $\{\mathbf{c}\}$

Vienanarių bazinių funkcijų matrica vektorinio argumento atveju

$$\mathbf{g}(x, y) = \begin{bmatrix} 1 & x & \cdots & x^{m-1} & y & \cdots & y^{m-1} \end{bmatrix}$$

$$\mathbf{G} = \begin{bmatrix} 1 & x_1 & \cdots & x_1^{m-1} & y_1 & \cdots & y_1^{m-1} \\ 1 & x_2 & \cdots & x_2^{m-1} & y_2 & \cdots & y_2^{m-1} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^{m-1} & y_n & \cdots & y_n^{m-1} \end{bmatrix}$$

$$\mathbf{G}^T \mathbf{G} \mathbf{c} = \mathbf{G}^T \mathbf{z} \quad \Rightarrow \quad \mathbf{c}$$

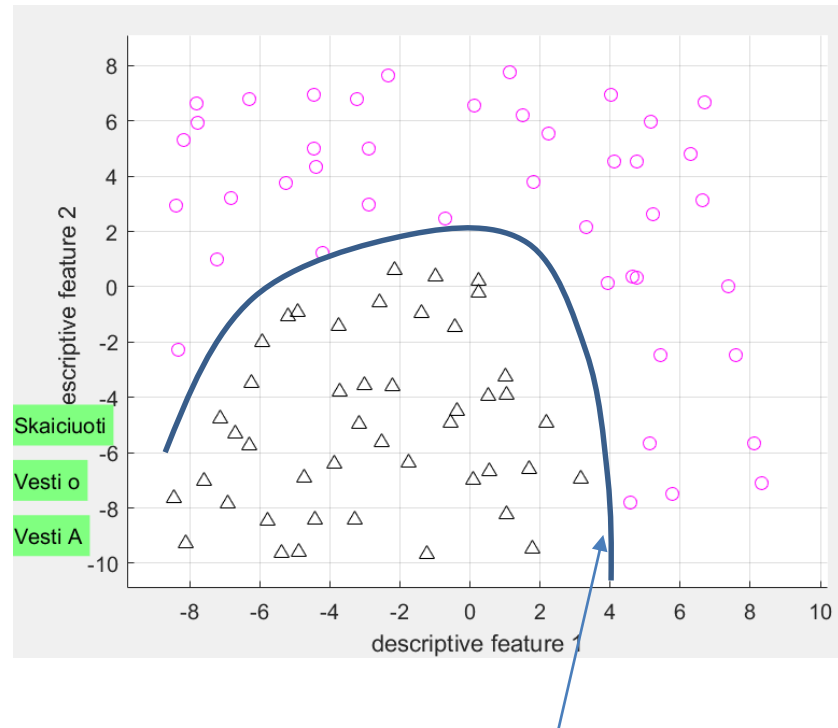
$$\mathbf{f}(x, y) = \begin{bmatrix} 1 & x & \cdots & x^{m-1} & y & \cdots & y^{m-1} \end{bmatrix} \mathbf{c}$$

- Parodėme, kad vektorinio argumento aproksimuojanti funkcija randama panašiai, kaip ir vieno argumento aproksimuojanti funkcija;
- Vieno argumento aproksimuojanti funkcija yra *regresijos kreivė* $f(x)$
- Vektorinio argumento atveju aproksimuojanti funkcija yra *regresijos paviršius* $f(x,y)$, kai kintamieji du) arba „hiperpaviršius“ $f(x_1, x_2, \dots)$, kai kintamųjų daugiau nei du;
- Taikydami vektorinio argumento taškų aibės aproksimavimą galime išspręsti *klasifikavimo uždavinį, kai apytiksliai randama kreivė, plokštumoje atskirianti vieną nuo kitos dvi skirtingai pažymėtas taškų aibės dalis*

Klasifikavimo uždavinio sprendimas (1)

pavyzdys Pvz_SMA_9_01x_klasifikavimas_mouse.m


- Plokštumoje duota taškų aibė, kuri susideda iš pagal dviejų *aprašančiųjų požymių (descriptive features)* reikšmes atskirtų klasių (pavyzdžiui, skritulių ir trikampių);
- Čia aprašantieji požymiai yra taškų x ir y koordinatės;



- Reikia apytiksliai nustatyti klases atskiriančią liniją

Klasifikavimo uždavinio sprendimas (2)

- Išplečiame duotųjų taškų (t.y. *apmokančios aibės, training set*) vaizdavimą į 3D erdvę;
- Skirtingoms klasėms priklausantiems taškams suteikiame z koordinates 0 ir 1 atitinkamai:




Klasifikavimo uždavinio sprendimas (3)

- Parinkę aproksimavimo eilę (pavyzdžiui, $m-1=3$) randame aproksimuojantį paviršių:

$$\mathbf{g}(x, y) = \begin{bmatrix} 1 & x & x^2 & x^3 & y & y^2 & y^3 \end{bmatrix}$$


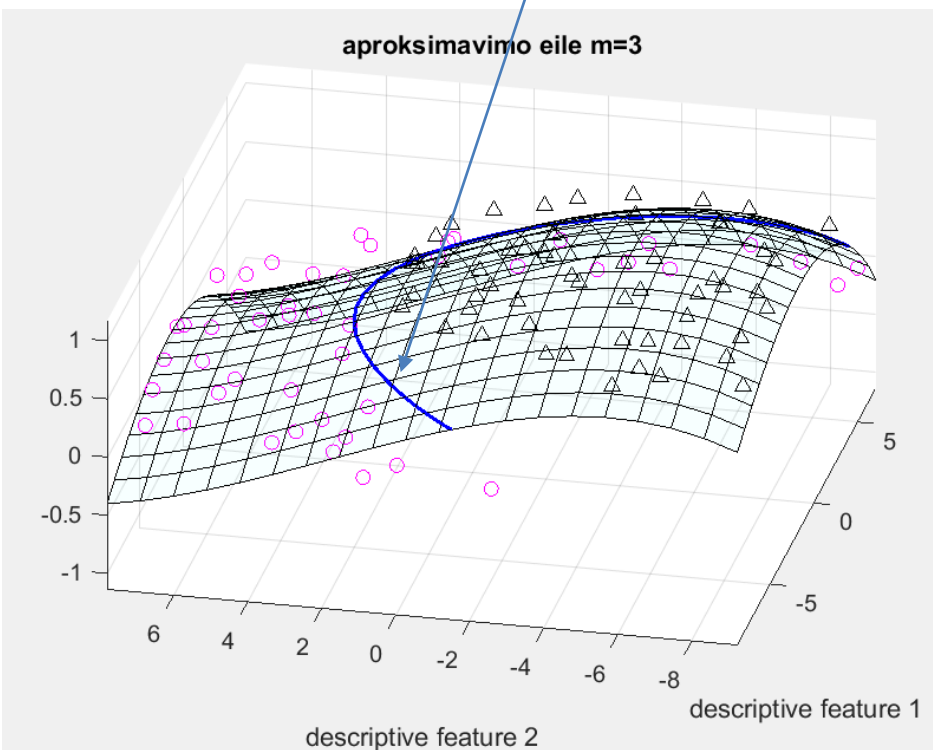
$$\mathbf{G}^T \mathbf{G} \mathbf{c} = \mathbf{G}^T \mathbf{z}$$

$$\mathbf{f}(x, y) = \begin{bmatrix} 1 & x & x^2 & x^3 & y & y^2 & y^3 \end{bmatrix} \mathbf{c}$$



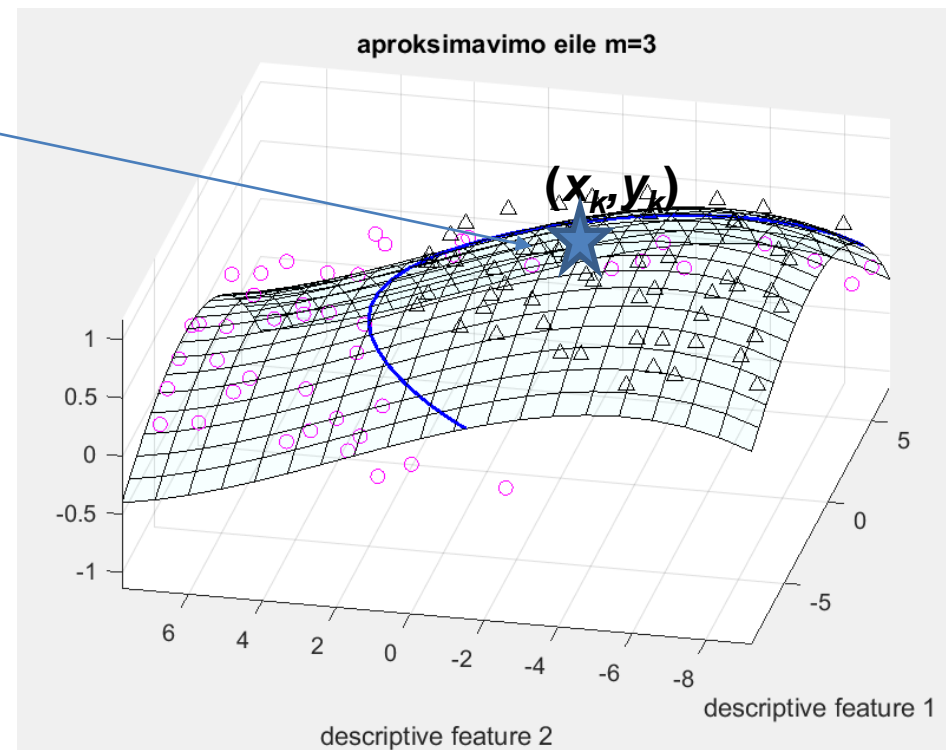

Klasifikavimo uždavinio sprendimas (4)

- Taškų klases skiria linija, kuria gautas paviršius kerta plokštumą $z=0.5$ (kadangi klasėms buvome parinkę reikšmes $z=0$ ir $z=1$);
- Rezultatą patogiau interpretuoti nagrinėjant projekciją, statmeną ašiai Oz



Klasifikavimo uždavinio sprendimas (5)

- Naujai duotas taškas (x_k, y_k) priklauso trikampiams, jeigu $f(x_k, y_k) \geq 0.5$. Priešingu atveju jis priklausytų skrituliams;



- Analogiškai skaičiuotume ir esant didesniai aprašančiųjų požymių skaičiui, tačiau rezultatą grafiškai pavaizduoti būtų keblu

SMA_09-1_Klausimai savikontrolei:

1. Suformuluokite funkcijos aproksimavimo uždavinį;
2. Naudodamiesi literatūra paaiškinkite, kaip aproksimavimo uždavinys sprendžiamas mažiausių kvadratų metodu;
3. Koks yra ryšys tarp aproksimuojamų taškų ir bazinių funkcijų skaičiaus;
4. Kokiu atveju aproksimavimo ir interpoliavimo uždaviniai yra tapatūs;
5. Kokia problema iškyla, jeigu bazinių funkcijų parenkame daugiau, nei yra aproksimuojamų taškų;